



**2025 – 2026 BAHAR DÖNEMİ
İST439 MAKİNE ÖĞRENMESİ
DÖNEM PROJESİ**

Hazırlayan : 2210329050 Ecemsu Arslan

Ders Sorumlusu : Doç. Dr. Duygu İçen

1.GİRİŞ

1.1 Projenin Amacı

Bu proje kapsamında İST439 Makine Öğrenmesi dersi boyunca işlenen makine öğrenmesi yöntemleri kullanılarak seçilen veri seti üzerinde tahmin ve öngörü modeli geliştirilmiştir.

2.VERİ SETİ VE PROBLEM TANIMI

2.1 Problem Tanımı

2.1.1 Çalışmanın Amacı

Çalışma bir Portekiz Yükseköğretim kurumundan toplanan “Predicting Students’ Dropout and Academic Success” veri seti üzerinden yürütülmüştür. Çalışmanın temel amacı makine öğrenmesi tekniklerini kullanarak öğrencilerin akademik hayatlarının başlarında okulu bırakma (dropout) riski altında olup olmadıklarını öngörmek ve risk altında olan öğrencileri destekleyecek stratejiler belirleyerek akademik başarısızlık oranlarını azaltmaya katkıda bulunmaktır.

2.1.2 Tahmin Edilen Değişken

Çalışmada, veri setinde yer alan “Target” değişkeni bağımlı değişken olarak belirlenmiştir. Bağımlı değişken kategorileri :

- “Dropout” : Okulu bırakanlar
- “Enrolled” : Eğitimine halen devam edenler
- “Graduate” : “Mezun olanlar

olmak üzere 3 farklı kategoriden oluşmaktadır.

2.2 Veri Seti

2.2.1 Veri Setinin Kaynağı

Çalışmada UCI Machine Learning Repository platformundan alınan “Predicting Students’ Dropout and Academic Success” veri seti kullanılmıştır. Bu veri seti, Portekiz’de bulunan Polytechnic Institute of Portalegre adlı yükseköğretim kurumundan toplanmıştır.

2.2.2 Veri Boyutu

Veri seti, 4424 gözlemden oluşmaktadır. 36 tane bağımsız ve 1 tane bağımlı değişken olmak üzere toplamda 37 değişken vardır.

2.2.3 Değişkenlerin Açıklanması

Veri setinde 36 bağımsız değişken bulunmaktadır. Çok boyutlu yapıyı daha iyi inceleyebilmek adına bu bağımsız değişkenler 4 ayrı sınıfa ayrılmıştır. Veri setinde yer alan bağımsız değişkenlerin ölçek türleri, veri tipleri ve açıklamaları şu şekildedir :

Değişken Grubu	Değişken Adı	Veri Tipi / Ölçek	Açıklama
Demografik Veriler	Marital status	Kategorik (Nominal)	Öğrencinin medeni durumu
	Gender	Kategorik (Kukla)	Cinsiyet (0: Kadın, 1: Erkek)
	Age at enrollment	Sürekli (Oran)	Kayıt olunan yaş
Sosyo-ekonomik ve Altyapı	Application mode	Kategorik (Nominal)	Başvuru tipi
	Application order	Kesikli (Sıralı)	Tercih sırası (1 ile 9 arası)
	Course	Kategorik (Nominal)	Öğrencinin kayıt yaptırdığı lisans programı
	Daytime/evening attendance	Kategorik (Kukla)	Eğitim türü (1: Gündüz, 0: Gece)
	Displaced	Kategorik (Kukla)	Öğrencinin yer değiştirme/göç durumu
	Debtor	Kategorik (Kukla)	Üniversiteye borçlu olma durumu (1: Evet, 0: Hayır)
	Tuition fees up to date	Kategorik (Kukla)	Harç ödemelerinin güncelliği (1: Düzenli, 0: Gecikmeli)

Değişken Grubu	Değişken Adı	Veri Tipi / Ölçek	Açıklama
	Scholarship holder	Kategorik (Kukla)	Bursiyer olma durumu (1: Evet, 0: Hayır)
Ebeveyn Arka Planı	Mother's qualification	Kategorik (Sıralı)	Annenin en son tamamladığı eğitim seviyesi
	Father's qualification	Kategorik (Sıralı)	Babanın en son tamamladığı eğitim seviyesi
	Mother's occupation	Kategorik (Nominal)	Annenin mesleki grubu
	Father's occupation	Kategorik (Nominal)	Babanın mesleki grubu
1. Dönem Akademik Performans	Curricular units 1st sem (credited)	Kesikli (Sayısal)	1. dönem muaf sayılan ders sayısı
	Curricular units 1st sem (enrolled)	Kesikli (Sayısal)	1. dönem kayıt olunan ders sayısı
	Curricular units 1st sem (evaluations)	Kesikli (Sayısal)	1. dönem girilen sınav/değerlendirme sayısı
	Curricular units 1st sem (approved)	Kesikli (Sayısal)	1. dönem başarıyla geçilen ders sayısı
	Curricular units 1st sem (grade)	Sürekli (0-20 Ölçek)	1. dönem not ortalaması (Portekiz 0-20 sistemi)

Değişken Grubu	Değişken Adı	Veri Tipi / Ölçek	Açıklama
	Curricular units 1st sem (without evaluations)	Kesikli (Sayısal)	1. dönem sınava girilmeyen ders sayısı
2. Dönem Akademik Performans	Curricular units 2nd sem (credited)	Kesikli (Sayısal)	2. dönem muaf sayılan ders sayısı
	Curricular units 2nd sem (enrolled)	Kesikli (Sayısal)	2. dönem kayıt olunan ders sayısı
	Curricular units 2nd sem (evaluations)	Kesikli (Sayısal)	2. dönem girilen sınav/değerlendirme sayısı
	Curricular units 2nd sem (approved)	Kesikli (Sayısal)	2. dönem başarıyla geçilen ders sayısı
	Curricular units 2nd sem (grade)	Sürekli (0-20 Ölçek)	2. dönem not ortalaması (Portekiz 0-20 sistemi)
	Curricular units 2nd sem (without evaluations)	Kesikli (Sayısal)	2. dönem sınava girilmeyen ders sayısı
Makroekonomik Göstergeler	Unemployment rate	Sürekli (Oran)	Ülkedeki güncel işsizlik oranı (%)
	Inflation rate	Sürekli (Oran)	Güncel enflasyon oranı (%)
	GDP	Sürekli (Oran)	Gayri Safi Yurtiçi Hasıla büyüme oranı (%)

3.YÖNTEMLER

3.1 Veri Ön İşleme

3.1.1 Değişken Seçimi

Modelin karmaşıklığını azaltmak ve aşırı öğrenmenin önüne geçmek için veri setindeki bazı değişkenler çalışmadan çıkarılmıştır :

- “Nationality” , “International” ve “Educational special needs” değişkenleri neredeyse tüm öğrencilerde aynı değerlere sahiptir. Bu değişkenler ayırt ediciliği olmadığından dolayı çıkarılmıştır.
- “Credited” (muaf sayılan krediler) ve “Without evaluations” (sınavsız geçilen dersler) değişkenleri öğrencilerin başarısına dair doğrudan bilgi vermemektedir. Gürültüye sebep olmamaları için bu değişkenler çıkarılmıştır.

3.1.2 Eksik Verilerin Ele Alınması

Makine öğrenmesi modellerine başlamadan önce kayıp gözlemlerin saptanması çok önemli bir adımdır. `isnull().sum()` analizi yapılarak veri setinde hiçbir eksik değer olmadığı sonucuna ulaşılmıştır.

Eksik Değer Analizi:

0

3.1.3 Normalizasyon ve Standartizasyon

Veri setinde yer alan bağımsız değişkenlerin ölçüm birimleri ve ölçek aralıkları birbirinden farklıdır. Bazı algoritmalar ölçüm sayısal olarak daha büyük olan değişkene ağırlık verir ve değişkenler aynı birimde değilse bu durum yanlılığa sebep olabilir. Bu sorunun önüne geçmek için modellemeye geçmeden önce ölçeklendirme ve standartizasyon yapılır.

```
scaler = StandardScaler()
```


```
X_scaled = scaler.fit_transform(X)
```

3.1.4 Boyut İndirgeme

Yüksek boyutlu veri setini incelemek ve sınıfların birbirinden ne kadar ayrılabilirdiğini görmek için boyut indirgeme yöntemi kullanılmıştır. Çalışmanın amacına uygun olacak şekilde sınıf etiketlerini hesaba katan gözetimli Lineer Diskriminant Analizi (LDA) uygulanmıştır. Veri setindeki hedef değişken 3 kategorilidir dolayısıyla LDA yöntemiyle elde edilebilecek maksimum bileşen sayısı “Sınıf sayısı – 1” formülünden 2 bulunmuştur. Sınıflar arası ayrımı en iyi temsil eden bileşenler LD1 ve LD2’dir. Veri, boyutları LD1 ve LD2 olan iki boyutlu koordinat sisteminde görselleştirilmiştir.

```
lda = LDA(n_components=2)
```

```
X_lda = lda.fit_transform(X_scaled, y)
```



Sınıflar yatay ekseninde daha başarılı şekilde ayrılmıştır. LD1 bileşeni, sınıfların ayrışmasında en çok etkisi olan yani varyans açıklama oranı en yüksek olan bileşendir. “Enrolled” grubunun diğer gruplarla iç içe geçtiğini görebiliriz. “Dropout” ve “Graduate” grupları ise yatay ekseninde birbirinden ayrılmaktadır.

4.UYGULAMA VE BULGULAR

4.1 Model Kurulumu

Uygulanacak olan makine öğrenmesi modellerinin hiç görmedikleri veriler üzerindeki genelleme performanslarını bulmak için veri kümesi %80 eğitim seti - % 20 test seti olacak şekilde ikiye bölünmüştür.

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42, stratify=y)
```

Modellerin %80 eğitim ve %20 test seti üzerindeki rastlantısal başarılarının önüne geçmek ve modelin kararlılığını gerçek hayata uygun şekilde görebilmek amacıyla hiperparametre optimizasyonu da yapılarak 5 Katlı Çapraz Geçerlilik uygulanmıştır.

```
grid = GridSearchCV(mp['model'], mp['params'], cv=5, scoring='accuracy', n_jobs=-1)
```

4.2 Algoritmaların Açıklanması

4.2.1 Çok Terimli Lojistik Regresyon

Bu model, bağımlı değişken kategorik olduğunda sınıflara ait gerçekleşme olasılıklarını doğrusal fonksiyon üzerinden modelleyen parametrik bir yöntemdir.

```
'Logistic Regression': {  
    'model': LogisticRegression(max_iter=2000),  
    'params': {'C': [0.1, 1, 10]}  
}
```

4.2.2 Naive Bayes Sınıflandırıcısı (Gaussian Naive Bayes)

Bu model, hedef değişkenin sınıfları verildiğinde bağımsız değişkenlerin birbirinden tamamen bağımsız olduğunu varsayan bir algoritmadır. Veri setindeki sürekli değişkenlerin dağılım özellikleri göz önünde bulundurularak Gaussian Naive Bayes modeli uygulanmıştır.

```
nb_model = GaussianNB()
```

4.2.3 Rastgele Orman (Random Forest)

Rastgele Orman algoritması, birden fazla karar ağacının aynı anda eğitilerek bir araya getirilmesiyle oluşan toplu öğrenme yöntemidir. Rastgele alt kümeler seçilerek birbirinden bağımsız ağaçlar üretir. Bu çalışmada modelin kararlılığını arttırmak için ağaç sayısı 100 olarak belirlenmiştir.

```
'Random Forest': {  
    'model': RandomForestClassifier(random_state=42),  
    'params': {'n_estimators': [100, 200], 'max_depth': [10, 20]}}
```

4.2.4 Karar Ağaçları (Decision Tree)

Karar Ağaçları, veri setindeki bağımsız değişkenleri belli kriterlere göre dallara ayırarak karar kuralları üreten gözetimli öğrenme algoritmasıdır. Her adımda en ayırt edici değişken ile bölünür. Ağacın kontrolsüz şekilde büyüyen aşırı öğrenmesinin önüne geçmek için maksimum derinlik ve karmaşıklık budama katsayısı gibi budama parametreleri optimize edilerek modele dahil edilmiştir.

```
'Decision Tree (Pruned)': {  
    'model': DecisionTreeClassifier(random_state=42),  
    'params': {  
        'ccp_alpha': [0.001, 0.01, 0.05], # Budama için  
        'max_depth': [5, 10, None]  
    }  
}
```

4.2.5 Destek Vektör Makineleri (Support Vector Machine – SVM)

Destek Vektör Makineler algoritması, sınıfları veri uzayında en başarılı şekilde ayıracak optimum hiper düzlemi ve karar sınırını bulmayı amaçlayan sınıflandırma algoritmasıdır. Algoritmanın temel amacı sınıfların sınır çizgilerine en yakın olan veri noktalarıyla karar düzlemi arasındaki mesafeyi maksimum yapmaktır. Veri setinde yer alan öğrencilerin durumları her zaman doğrusal olarak ayrılmadığından dolayı verileri daha yüksek boyutlu uzaya taşıyarak doğrusal olmayan sınırların çizilmesini sağlayan RBF Kernel kullanılmıştır.

```
'SVM': {  
    'model': SVC(probability=True),  
    'params': {'C': [1, 10], 'kernel': ['rbf', 'linear']}  
}
```

4.3 Model Değerlendirme

4.3.1 Çok Terimli Lojistik Regresyon

LOJISTIK REGRESYON

Test Doğruluğu: %74.35

	precision	recall	f1-score	support
Dropout	0.75	0.78	0.77	284
Enrolled	0.43	0.23	0.30	159
Graduate	0.79	0.90	0.84	442
accuracy		0.74		885
macro avg	0.66	0.64	0.64	885
weighted avg	0.71	0.74	0.72	885

Çok terimli lojistik regresyon modeli, test setinde %74.35 oranında genel doğruluk (Accuracy) başarısı göstermiştir. Model, okulu bırakma riski olan öğrencileri yakalamada dengeli performans göstermiştir. Recall değeri %78 çıkmıştır ve bu da modelin okulu bırakacak öğrencilerin %78'ini doğru ayırt edebildiğini gösterir. Okula devam eden öğrencilerde ciddi bir performans düşüşü yaşanmıştır. Kesinlik %43'e ve duyarlılık %23'e düşmüştür. Bu performans düşüşü devam edenler grubunun diğer iki grubun da özelliklerini taşımasından kaynaklanır. Mezun grubu ise modelin en başarılı olduğu gruptur. Modelin mezun olan öğrencileri yakalama oranı %90 (Recall) gibi yüksek düzeyde çıkmıştır.

4.3.2 Naive Bayes Sınıflandırıcısı (Gaussian Naive Bayes)

NAIVE BAYES

Test Doğruluğu: %64.52

	precision	recall	f1-score	support
Dropout	0.66	0.69	0.68	284
Enrolled	0.30	0.33	0.31	159
Graduate	0.78	0.73	0.75	442
accuracy		0.65		885
macro avg	0.58	0.58	0.58	885
weighted avg	0.66	0.65	0.65	885

Gaussian Naive Bayes modeli, test setinde %64.52 doğruluk oranı ile en düşük performansı göstermiştir. Okulu bırakanlar grubunun F1-score değeri %68 çıkmıştır ve diğer modellerin gerisinde kalmıştır. Devam edenler grubunda daha da düşerek F1-score %31 çıkmıştır. Mezun olan grubunda %78 kesinlik ve %73 duyarlılık ile daha başarılı olmuştur.

4.3.3 Rastgele Orman (Random Forest)

RASTGELE ORMAN

Test Doğruluğu: %77.40

	precision	recall	f1-score	support
Dropout	0.80	0.75	0.77	284
Enrolled	0.59	0.38	0.46	159
Graduate	0.80	0.93	0.86	442
accuracy		0.77		885
macro avg	0.73	0.69	0.70	885
weighted avg	0.76	0.77	0.76	885

Rastgele orman algoritması, test setinde %77.40 doğruluk (Accuracy) değerine ulaşarak çalışmadaki en başarılı model olmuştur. Okulu bırakanlar grubunda %80 kesinlik ve %75 duyarlılık ile okulu bırakan öğrencileri en iyi tahmin eden modeldir. Modelin “okulu bırakacak” şeklinde tahmin ettiği 100 öğrenciden 80’i gerçekten okulu bırakmıştır. Gerçekten okulu bırakma risklerinin %75’i başarıyla yakalanmıştır. Devam edenler grubunda kesinlik %59 çıkmıştır ve diğer modellere göre yüksektir. Mezun olanlar sınıfında ise %80 kesinlik ve %93 duyarlılık ile F1- score %86’ya kadar çıkmıştır.

4.3.4 Karar Ağaçları (Decision Tree)

KARAR AĞACI (BUDANMIŞ)

Test Doğruluğu: %74.01

	precision	recall	f1-score	support
Dropout	0.74	0.73	0.73	284
Enrolled	0.48	0.29	0.36	159
Graduate	0.79	0.91	0.85	442
accuracy		0.74		885
macro avg	0.67	0.64	0.65	885
weighted avg	0.72	0.74	0.72	885

Karar ağacı modeli, %74 doğruluk oranı göstermiştir ve lojistik regresyon modeli ile benzer sonuç vermiştir. Bu model için de en yüksek F1-score %85 değeri ile mezun olanlar grubuna aittir ve onu %73 değeriyle okulu bırakanlar grubu izlemektedir.

4.3.5 Destek Vektör Makineleri (Support Vector Machine – SVM)

SVM (RBF)

Test Doğruluğu: %74.12

	precision	recall	f1-score	support
Dropout	0.81	0.72	0.76	284
Enrolled	0.45	0.31	0.37	159
Graduate	0.77	0.91	0.84	442
accuracy		0.74		885
macro avg	0.68	0.65	0.65	885
weighted avg	0.72	0.74	0.73	885

SVM modeli, test verisinde %74.12 genel doğruluk oranı elde etmiştir. Okulu bırakanlar grubunda %81 kesinlik (Precision) değeri ile en yüksek kesinlik değerine ulaşan model olmuştur. Modelin “okulu bırakacak” dediği 100 öğrenciden 81’i gerçekten okulu bırakmıştır. Duyarlılık (Recall) oranı ise %72 çıkmıştır.

5.MODEL KARŞILAŞTIRMALARI

Sıra	Model Algoritması	CV Doğruluğu (%)	Test Doğruluğu (%)
1	Rastgele Orman (Random Forest)	%76.55	%77.40
2	Lojistik Regresyon	%74.99	%74.35
3	Destek Vektör Makinesi (SVM - RBF)	%75.16	%74.12
4	Budanmış Karar Ağacı	%74.37	%74.01
5	Naive Bayes (Gaussian NB)	%66.94	%64.52

Elde edilen sonuçlar değerlendirildiğinde hem çapraz geçerlilikte (%76.55) hem de test verisinde (%77.40) en yüksek başarıyı gösteren model Random Forest olmuştur. Tüm modellerin doğruluk değerleri ve çapraz geçerlilik değerleri arasında az fark vardır. Bu durum modellerin eğitim verilerini ezberlemediğini gösterir. Lojistik regresyon (%74.35) ve SVM (%74.12) modelleri birbirine oldukça yakın performans göstermiştir. Naive Bayes modeli ise %64.52 test doğruluğu ile en düşük performansı göstermiştir. Akademik başarıyı etkileyen sosyo-ekonomik durum ve dönem notları gibi değişkenler yüksek korelasyona sahiptir ve bu durum naive bayes modelinin koşullu bağımsızlık varsayımını bozmuştur.

5.1 Ek Analiz : İkili Sınıflandırma

Çalışmanın “Model Değerlendirme” aşamasında en düşük kesinlik, duyarlılık ve F1-score değerlerini veren hedef grup “Enrolled” yani okula devam edenler grubu olmuştur. Sınıfları daha iyi ayırabilmek ve daha başarılı sonuç almak için “Enrolled” grubu veri setinden çıkarılmıştır ve ikili sınıflandırma yapıldığında sonucun nasıl değiştiği Rastgele Orman algoritmasıyla incelenmiştir.

Hedef Sınıf (Target)	Kesinlik (Precision)	Duyarlılık (Recall)	F1-Skoru (F1-Score)	Örneklem (Support)
Dropout (Okul Terki)	0.94	0.82	0.87	284
Graduate (Mezun)	0.89	0.96	0.93	442
Genel Doğruluk (Accuracy)			%90.77	726

“Enrolled” grubunun çıkarılmasıyla birlikte Rastgele Orman modelinin genel doğruluk (Accuracy) değeri %77.40’tan %90.77’ye çıkmıştır. Bu durum, okula devam edenlere ait veri noktalarının gürültüye

sebepe olduğunu göstermektedir. “Dropout” sınıfındaki kesinlik (Precision) değeri %94 gibi oldukça yüksek bir değere ulaşmıştır. Model, “okulu bırakacak” dediğinde bu tahminin doğruluk payı %94’tür.

“Dropout” grubuna ait duyarlılık (Recall) değeri ise %82’dir ve okulu bırakma riskini taşıyan öğrencilerin büyük bir kısmının başarıyla yakalandığı görülmektedir.

6.SONUÇ VE DEĞERLENDİRME

Bu çalışmada Portekiz yükseköğretim kurumundaki öğrencilerin demografik, sosyo-ekonomik ve akademik geçmiş verileri analiz edilerek okulu bırakma (dropout) riskleri makine öğrenmesi algoritmalarıyla modellenmiştir. Analiz sürecinde veri ön işleme, 5-katlı çapraz geçerlilik, GridSearchCV hiperparametre optimizasyonu ve model doğrulama yapılmıştır.

Eğitilen 5 farklı algoritma arasında hem çapraz geçerlilikte hem de test verisi üzerinde en yüksek genel doğruluğu ve kararlılığı Rastgele Orman (Random Forest) modeli vermiştir. Modellerin genel performansı yaklaşık olarak %77 seviyelerinde çıkmıştır ve bunun sebebi okula aktif olarak devam eden öğrenci grubunun (Enrolled) belirsizliğinden kaynaklanmıştır. Bu grubun yokluğundaki başarıyı test etmek için İkili Sınıflandırma senaryosu analiz edilmiştir. “Enrolled” grubu çıkarıldığında Rastgele Orman modelinin genel doğruluk oranının %90.77 seviyesine yükseldiği saptanmıştır. Modelin “okulu bırakacak” tahmini yaptığı öğrencileri yakalama oranı (Precision) %94 gibi mükemmel yakın bir düzeye ulaşmıştır.

Elde edilen bulgular ışığında, yükseköğretim kurumunda öğrencilerin okula bırakma riskini en aza indirmek ve akademik başarıyı maksimize etmek için şu stratejiler önerilebilir :

- Erken Uyarı Sistemi : Erken uyarı sistemi geliştirilerek özellikle 1. Ve 2. Dönem dönem not ortalamaları kritik eşiğin altına düşen öğrenciler otomatik olarak “Riskli (Okulu Bırakacak)” olarak işaretlenmelidir.
- Danışmanlık Hizmeti : Üniversite yönetimi psikolojik danışmanlık, burs ve finansal destek kaynaklarını okulu bırakma riski en yüksek olan öğrencilere yönlendirmelidir.
- Okula Devam Edenler İçin Takip Mekanizması : Modellerin üçlü sınıflandırmada en çok zorlandığı eğitimi devam eden (“Enrolled”) öğrenciler için dinamik takipler yapılmalıdır. Bu gruptaki öğrencilerin başarı durumları dönem sonunda model üzerinden incelenerek risk eğilimleri erkenden saptanmalıdır.
- Sosyo-Ekonomik Destek Programları : Modellerin değişken önem düzeyleri arka planda incelenmiştir ve Random Forest modeline göre en yüksek önem derecesine sahip ilk üç değişken sırasıyla 2. Dönem Onaylanan Kredi Sayısı, 2. Dönem Not Ortalaması ve Öğrencinin Burs Durumu olarak saptanmıştır. Öğrencilerin finansal durumlarının okul terki üzerinde tetikleyici olduğu saptanmıştır. Bu doğrultuda sosyo-ekonomik durumu düşük olan öğrencilere yönelik burs ve asistanlık programları oluşturulmalıdır.

KAYNAKÇA

Realinho, V., Machado, J., Baptista, L., & Martins, M.V. (2022). Predicting Student Dropout and Academic Success. UCI Machine Learning Repository.

İçen, D. (2025). *IST439 Makine Öğrenmesi Dersi Ders ve Uygulama Notları*. Hacettepe Üniversitesi İstatistik Bölümü. (Ders materyali)

Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly Media.

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.